

LAPORAN JURNAL TOPIK KESEHATAN

Rancangan Implementasi Big Data untuk Prediksi Keputusan Rawat Inap atau Pulang Pasien IGD Sebagai Pendukung Operasional Rumah Sakit



Disusun oleh:

Muhammad Nurikhsan	123140057
Miftahul khoiriyah	123140064
Andini Rahma Kemala	123140067
Giovan Lado	123140068
Zahwa Natasya Hamzah	123140069
Aditya Hot Martua Sihite	123140114
Aryasatya Widyatna Akbar	123140164
Rian Rafael Sangap Tamba	123140190

Mata Kuliah: IF25-3024 - Big Data

Dosen Pengampu : Meida Cahyo Untoro, S.Kom., M.Kom.

PROGRAM STUDI TEKNIK INFORMATIKA

INSTITUT TEKNOLOGI SUMATERA

2026

DAFTAR ISI

DAFTAR ISI.....	2
ABSTRAK.....	5
BAB I.....	6
PENDAHULUAN.....	6
1.1. Latar Belakang.....	6
1.2. Permasalahan.....	6
1.3. Research gap.....	7
1.4. Tujuan penelitian.....	7
1.5. Kontribusi Penelitian.....	7
1.6. Batasan Penelitian.....	7
1.7. Struktur Paper.....	8
1.7.1 Bab I Pendahuluan.....	8
1.7.2 Bab II Kajian Literatur.....	8
1.7.3 Bab III Metodologi.....	8
1.7.4 Bab IV Desain Eksperimen.....	8
1.7.5 Bab V Hasil yang Diharapkan.....	8
1.7.6 Bab VI Kesimpulan dan Saran.....	8
BAB II.....	9
KAJIAN LITERATUR.....	9
2.1. Review Jurnal.....	9
2.1.1 Arsitektur Big Data dan Integrasi Data Layanan Kesehatan.....	9
2.1.2 Prediksi Keputusan Rawat Inap atau Pulang di IGD.....	9
2.1.3 Efisiensi Operasional dan Perencanaan Kapasitas.....	9
2.1.4 Tata Kelola Data dan Pemantauan Model.....	9
2.1.5 Sintesis Metodologis Antarstudi.....	10
2.2 Tabel Perbandingan.....	10
2.3. Research Gap dan Posisi Penelitian.....	11
2.4. Implikasi Literatur terhadap Rancangan Penelitian.....	11
2.5: Kerangka Konseptual Penelitian.....	12
2.1.1 Konsep Big Data dalam Operasional Layanan Kesehatan.....	13
2.1.2 Arsitektur Referensi Big Data untuk Keputusan Operasional.....	13
2.1.3 Optimasi Aliran Pasien dan Prediksi Kebutuhan Tempat Tidur.....	14
2.1.4 Penjadwalan Dinamis Tenaga Medis Berbasis Prediksi Lonjakan.....	15
2.1.5 Tata Kelola Data (Data Governance) dan Operasionalisasi Model (MLOps)....	15
2.2 Tabel Perbandingan (sudah mencakup klasifikasi literatur).....	16
2.3. Identifikasi Research Gap.....	20
2.4. Kontribusi Jurnal terhadap Penelitian Sebelumnya.....	21
BAB III.....	23
METODOLOGI.....	23

3.1. Arsitektur Sistem / Framework.....	23
3.1.1. Data Governance dan Audit Log.....	24
3.2. Sumber Data & Pengumpulan Data.....	24
3.2.1 Sumber Data.....	24
3.2.3 Strategi Pengumpulan.....	25
3.2.4 Karakteristik Big Data.....	25
3.3. Pipeline Data & Processing.....	26
3.4. Metode Analisis / Model.....	26
3.4.1 Algoritma/Model.....	27
BAB IV	
DESAIN EKSPERIMEN.....	28
4.1 Skenario Eksperimen.....	28
4.2 Baseline / Pembandingan.....	28
4.3 Environment Eksperimen.....	28
4.4 Metrik Evaluasi.....	28
4.5 Rangkuman Desain Eksperimen.....	28
BAB V.....	29
HASIL YANG DIHARAPKAN.....	29
5.1 Hipotesis Hasil Penelitian.....	29
5.2 Rancangan Visualisasi Hasil.....	29
5.3 Kontribusi yang Diharapkan.....	29
BAB VI	
KESIMPULAN DAN RENCANA KERJA.....	30
DAFTAR PUSTAKA.....	31
LAMPIRAN.....	33
Rencana Pengerjaan Tugas Besar.....	35

ABSTRAK

Instalasi Gawat Darurat (IGD) merupakan unit kritis dalam rumah sakit yang menghadapi tantangan tingginya volume kunjungan pasien, keterbatasan sumber daya, serta kebutuhan pengambilan keputusan penting dalam operasional Instalasi Gawat Darurat (IGD) adalah penentuan disposition pasien, yaitu apakah pasien perlu dirawat inap, dipulangkan, atau dirujuk. Dalam praktiknya, keputusan ini seringkali belum didukung oleh integrasi data yang optimal maupun analitik berbasis data secara real-time.

Penelitian ini mengusulkan rancangan implementasi Big Data untuk mendukung pengambilan keputusan operasional Instalasi Gawat Darurat (IGD) melalui pendekatan arsitektur sistem dan pipeline data secara end-to-end. Data dikumpulkan dari berbagai sumber seperti sistem IGD, Electronic Health Records (EHS), dan data klaim BPJS, kemudian diintegrasikan ke dalam lingkungan data lake dan diproses menggunakan kombinasi batch dan stream processing. Model analitik digunakan sebagai bagian dari pipeline untuk menghasilkan prediksi disposition pasien yang selanjutnya disajikan dalam bentuk dashboard sebagai komponen decision support system.

Hasil penelitian ini berupa blueprint arsitektur Big Data yang terintegrasi dan scalable untuk mendukung pengolahan data dan penyajian insight secara real-time. Rancangan ini diharapkan dapat meningkatkan efisiensi operasional Instalasi Gawat Darurat (IGD), mengurangi waktu tunggu pasien, serta membantu optimalisasi pemanfaatan sumber daya rumah sakit.

Kata kunci : *Big Data, Instalasi Gawat Darurat (IGD), Disposition pasien, Arsitektur sistem, Pipeline data, Decision support.*

BAB I

PENDAHULUAN

1.1. Latar Belakang

Instalasi Gawat Darurat (IGD) merupakan unit layanan dengan tekanan operasional tinggi karena harus merespons kedatangan pasien yang cepat, tidak terjadwal, dan beragam tingkat urgensinya. Dalam kondisi tersebut, rumah sakit perlu menjaga keseimbangan antara kecepatan layanan, ketepatan keputusan klinis awal, dan ketersediaan sumber daya. Alur pasien yang tidak terintegrasi dapat memicu bottleneck dan menurunkan efisiensi operasional [3].

Transformasi digital kesehatan menghasilkan data operasional dalam jumlah besar, seperti data triase, pergerakan pasien, dan data klinis penunjang. Namun, data tersebut sering tersebar lintas sistem dan format, sehingga belum optimal untuk mendukung keputusan operasional yang cepat [14].

Pada konteks IGD, keputusan rawat inap atau pulang menjadi titik kritis karena memengaruhi alur pasien, kapasitas tempat tidur, dan beban kerja layanan. Penelitian menunjukkan bahwa model machine learning berbasis data triase dapat meningkatkan ketepatan prediksi kebutuhan rawat inap [6][10], dan pendekatan prediktif juga bermanfaat untuk perencanaan kapasitas tempat tidur [2].

Meski begitu, banyak studi masih berfokus pada performa model secara terpisah. Padahal, implementasi di rumah sakit memerlukan rancangan terintegrasi yang mencakup arsitektur data, pipeline pemrosesan, kualitas data, dan penyajian hasil analitik untuk keputusan operasional harian [8]. Karena itu, penelitian ini berfokus pada perancangan implementasi big data terintegrasi untuk mendukung keputusan rawat inap atau pulang pasien IGD secara cepat, konsisten, dan akuntabel.

1.2. Permasalahan

Berdasarkan latar belakang yang telah diuraikan, permasalahan dalam penelitian ini difokuskan pada bagaimana penerapan Big Data dapat mendukung operasional IGD. Adapun rumusan masalah dalam penelitian ini adalah sebagai berikut :

1. Bagaimana merancang pipeline big data end-to-end untuk mengolah data kunjungan IGD menjadi informasi operasional yang mendukung keputusan rawat inap atau pulang?
2. Bagaimana merancang arsitektur sistem yang mencakup ingestion, storage, processing, analytics, dan serving agar dapat diterapkan secara bertahap pada lingkungan rumah sakit dengan kapasitas infrastruktur yang beragam?
3. Bagaimana mengintegrasikan model prediktif ke dalam alur operasional IGD agar hasil analitik dapat digunakan sebagai pendukung keputusan secara tepat waktu?
4. Bagaimana merancang tata kelola data dan pemantauan model agar sistem tetap andal, aman, dan adaptif terhadap perubahan data operasional?

1.3. Research gap

Kajian literatur menunjukkan empat celah utama pada implementasi analitik data di operasional IGD. Pertama, banyak studi menekankan akurasi model, tetapi belum menguraikan integrasinya ke pipeline data dan alur keputusan operasional end-to-end [5]. Kedua, sebagian besar pendekatan dikembangkan pada infrastruktur digital yang matang, sehingga belum tentu sesuai untuk rumah sakit dengan kesiapan sistem yang beragam [14]. Ketiga, kualitas data dan pemantauan perubahan distribusi data sering diperlakukan terpisah dari desain sistem, padahal keduanya krusial untuk menjaga keandalan model [12]. Keempat, kebutuhan IGD menuntut keluaran cepat yang dapat langsung ditindaklanjuti, sementara banyak rancangan masih dominan pada analisis periodik dan belum memperkuat komponen serving [3]. Berdasarkan celah tersebut, penelitian ini berfokus pada perancangan implementasi big data terintegrasi untuk mendukung keputusan rawat inap atau pulang di IGD.

1.4. Tujuan penelitian

Berdasarkan permasalahan dan research gap yang telah diidentifikasi, penelitian ini memiliki tujuan sebagai berikut:

1. Merancang arsitektur implementasi big data untuk operasional IGD yang terstruktur, modular, dan dapat diterapkan secara bertahap.
2. Merancang pipeline data end-to-end, mulai dari ingestion, validasi, preprocessing, hingga serving insight operasional.
3. Mengembangkan model prediksi keputusan rawat inap atau pulang sebagai komponen inti pendukung keputusan operasional IGD.
4. Merancang mekanisme tata kelola data dan pemantauan model untuk menjaga kualitas data dan stabilitas performa model dari waktu ke waktu.

1.5. Kontribusi Penelitian

Kontribusi utama penelitian ini adalah sebagai berikut:

1. Menyediakan rancangan implementasi terpadu yang menghubungkan arsitektur sistem, pipeline data, dan model prediktif dalam satu kerangka operasional.
2. Memperkuat penerapan prediksi keputusan rawat inap atau pulang berbasis data triase dan data kunjungan awal yang relevan untuk kebutuhan layanan IGD [4].
3. Menyajikan acuan implementatif bagi rumah sakit untuk meningkatkan efisiensi alur pasien serta mendukung perencanaan kapasitas layanan secara lebih proaktif [2].

1.6. Batasan Penelitian

Batasan penelitian ditetapkan agar ruang lingkup tetap terarah:

1. Penelitian difokuskan pada konteks operasional IGD dengan keluaran utama keputusan rawat inap atau pulang.

2. Penelitian berada pada level rancangan konseptual-teknis dan validasi eksperimental, belum sampai tahap implementasi produksi penuh di rumah sakit.
3. Integrasi lintas sistem institusional skala penuh diposisikan sebagai arah pengembangan lanjutan.
4. Tata kelola data dan pemantauan model dibahas pada kerangka implementasi operasional untuk menjaga kualitas data dan mengantisipasi perubahan distribusi data [12].

1.7. Struktur Paper

1.7.1 Bab I Pendahuluan

Mencangkup latar belakang, rumusan masalah, research gap, tujuan penelitian, kontribusi serta batasan penelitian dalam penelitian ini.

1.7.2 Bab II Kajian Literatur

Menyajikan review terhadap 15 jurnal yang relevan, tabel perbandingan sistematis, identifikasi research gap, serta kontribusi jurnal terhadap penelitian sebelumnya.

1.7.3 Bab III Metodologi

Menjelaskan arsitektur sistem dan framework yang diusulkan, sumber data dan mekanisme pengumpulan data, pipeline pemrosesan data, serta metode analisis dan model yang digunakan.

1.7.4 Bab IV Desain Eksperimen

Menguraikan skenario eksperimen, baseline pembanding, lingkungan eksperimen, matrik evaluasi, serta rangkuman keseluruhan desain eksperimen.

1.7.5 Bab V Hasil yang Diharapkan

Membahas hipotesis hasil penelitian, rancangan visualisasi hasil, dan kontribusi yang diharapkan dari penerapan framework yang diusulkan.

1.7.6 Bab VI Kesimpulan dan Saran

Merangkum tujuan, pendekatan, dan kontribusi penelitian, mengidentifikasi keterbatasan yang telah dikenali, serta memaparkan rencana pengembangan ke depan.

BAB II

KAJIAN LITERATUR

2.1. Review Jurnal

2.1.1 Arsitektur Big Data dan Integrasi Data Layanan Kesehatan

Perkembangan big data di kesehatan bergerak dari pelaporan pasif menuju pendukung keputusan operasional. Perubahan ini menuntut arsitektur yang mampu mengintegrasikan data lintas unit, memproses data tepat waktu, dan menyajikan keluaran yang dapat langsung digunakan [3]. Tantangan utamanya bukan hanya volume data, tetapi juga heterogenitas sumber dan format yang memicu fragmentasi informasi.

Integrasi HIS terbukti memperbaiki koordinasi antar unit dan menurunkan hambatan alur layanan [3]. Artinya, nilai analitik sangat ditentukan oleh kualitas integrasi data di hulu. Pada institusi dengan kesiapan infrastruktur yang beragam, pendekatan implementasi bertahap lebih realistis dibanding transformasi total satu tahap [14]. Hal ini relevan untuk operasional IGD yang menuntut stabilitas sistem selama proses digitalisasi.

2.1.2 Prediksi Keputusan Rawat Inap atau Pulang di IGD

Di IGD, keputusan rawat inap atau pulang berdampak langsung pada alur pasien dan utilisasi sumber daya. Studi menunjukkan data triase dan data kunjungan awal memiliki daya prediksi yang kuat terhadap kebutuhan rawat inap [6]. Karena itu, prediksi dapat dilakukan lebih dini tanpa menunggu data klinis lanjutan lengkap.

Model berbasis gradient boosting, termasuk XGBoost, dilaporkan memiliki performa kompetitif untuk prediksi admisi pasien dewasa [6]. Nilai praktis model meningkat ketika interpretasinya jelas bagi pengguna operasional, sebagaimana ditunjukkan pendekatan explainable AI [5]. Temuan lain juga menegaskan bahwa prediksi berbasis data triase efektif untuk mendukung keputusan operasional fase awal layanan [10].

2.1.3 Efisiensi Operasional dan Perencanaan Kapasitas

Selain prediksi individual, operasional rumah sakit memerlukan proyeksi kapasitas layanan. Prediksi kebutuhan tempat tidur dengan machine learning membantu perencanaan kapasitas secara proaktif saat permintaan berfluktuasi [2]. Kombinasi machine learning dan optimasi juga dilaporkan meningkatkan kualitas penugasan tempat tidur serta menyeimbangkan beban layanan [1].

Pada level institusi, adopsi big data analytics berkaitan dengan peningkatan efisiensi proses IGD [8]. Namun, dampak tersebut umumnya muncul bila analitik terhubung ke proses kerja nyata dan didukung tata kelola data yang memadai.

2.1.4 Tata Kelola Data dan Pemantauan Model

Keberhasilan implementasi analitik kesehatan tidak hanya bergantung pada algoritma. Kualitas data, interoperabilitas, keamanan, dan kesiapan tata kelola merupakan faktor penentu, terutama pada lingkungan negara berkembang [14]. Karena itu, tata kelola data perlu ditempatkan sebagai bagian inti rancangan sistem.

Dinamika data operasional juga menimbulkan risiko perubahan distribusi data yang dapat menurunkan kinerja model. Studi data drift menekankan pentingnya monitoring berkelanjutan agar model tetap reliabel setelah dioperasikan [12]. Dengan demikian, implementasi big data untuk IGD perlu memadukan integrasi data, pipeline yang andal, model prediktif operasional, serta mekanisme tata kelola dan pemantauan performa.

2.1.5. Sintesis Metodologis Antarstudi

Secara metodologis, studi terdahulu dapat dikelompokkan menjadi tiga pendekatan utama. Kelompok pertama berfokus pada prediksi individu pasien menggunakan data triase awal untuk memperkirakan kebutuhan rawat inap [6]. Kelompok kedua menitikberatkan prediksi kapasitas layanan, khususnya kebutuhan tempat tidur, berbasis pola historis [2]. Kelompok ketiga memadukan analitik dengan optimasi operasional untuk meningkatkan efisiensi alokasi sumber daya [1]. Perbedaan ini menunjukkan bahwa kontribusi penelitian tidak cukup dinilai dari akurasi model semata, tetapi juga dari sejauh mana hasil analitik dapat diintegrasikan ke alur keputusan operasional. Karena itu, penelitian ini menempatkan integrasi arsitektur, pipeline, dan serving sebagai fokus implementasi.

2.2 Tabel Perbandingan

Tabel berikut merangkum studi yang paling relevan terhadap fokus penelitian, yaitu implementasi big data untuk mendukung keputusan rawat inap atau pulang pada operasional IGD.

No	Referensi	Fokus Studi	Metode/Teknologi	Temuan Utama	Keterbatasan
1	Schäfer et al. [1]	Patient-bed assignment operasional	ML + optimasi	Alokasi tempat tidur lebih adaptif terhadap kebutuhan layanan	Sinkronisasi data antar unit masih menantang
2	Tello et al. [2]	Prediksi kebutuhan bed demand	ML regression	Prediksi kapasitas membantu perencanaan tempat tidur	Butuh data historis stabil
3	Nguyen et al. [3]	Dampak HIS pada patient flow	Systematic review	Integrasi HIS meningkatkan manajemen alur pasien	Implementasi kompleks di sistem lama
4	Arnaud et al. [4]	Prediksi hospitalisation dari data IGD	Progressive prediction	Prediksi dini mendukung keputusan awal layanan	Integrasi operasional belum mendalam
5	Moreno-Sánchez et al. [5]	Prediksi alur pasien IGD	Explainable AI	Model lebih interpretatif untuk pengguna layanan	Validasi lintas institusi terbatas
6	Patel et al. [6]	Prediksi admisi	Gradient boosting	Akurasi prediksi rawat	Isu generalisasi konteks

		pasien dewasa		inap kompetitif	lokal
7	Imhoff et al. [7]	Peningkatan waktu admisi IGD	Quality improvement	Waktu menuju admisi dapat dipersingkat	Bergantung pada kesiapan proses internal
8	Senitan & Alzahrani [8]	Efisiensi IGD berbasis BDA	Retrospective analytics	BDA meningkatkan efisiensi operasional IGD	Bergantung pada kesiapan data institusi
9	Hussain et al. [9]	Analitik data untuk keputusan klinis	BDA + AI	Analitik meningkatkan dukungan keputusan klinis	Fokus lebih klinis daripada pipeline operasional
10	Tschoellitsch et al. [10]	Prediksi admisi dari data triase	ML triage-based prediction	Data triase efektif untuk prediksi admisi dini	Perlu adaptasi ke lingkungan implementasi lokal

2.3. Research Gap dan Posisi Penelitian

Berdasarkan sintesis 10 studi pada Tabel 2.1, terdapat empat celah utama. Pertama, banyak penelitian berfokus pada performa model prediktif, namun belum menguraikan integrasi model ke pipeline operasional end-to-end [5]. Kedua, sebagian pendekatan dikembangkan pada lingkungan dengan infrastruktur relatif matang, sehingga tantangan penerapan pada institusi dengan kesiapan sistem beragam masih tinggi [14]. Ketiga, pengelolaan kualitas data dan pemantauan perubahan distribusi data sering diperlakukan terpisah dari desain implementasi sistem [12]. Keempat, kebutuhan operasional IGD menuntut keluaran cepat dan dapat ditindaklanjuti, sementara banyak studi masih menitikberatkan evaluasi analitik periodik [3].

Penelitian ini memosisikan kontribusi pada perancangan implementasi big data yang terintegrasi untuk mendukung keputusan rawat inap atau pulang di IGD. Rancangan mencakup arsitektur sistem, pipeline pemrosesan data, model prediksi, serta komponen serving agar hasil analitik dapat digunakan dalam pengambilan keputusan operasional harian secara lebih responsif [8]. Dengan posisi tersebut, penelitian ini diharapkan menjembatani kebutuhan akademik dan kebutuhan implementatif di lingkungan layanan kesehatan.

2.4. Implikasi Literatur terhadap Rancangan Penelitian

Temuan literatur memberi implikasi langsung terhadap rancangan penelitian ini. Pertama, dari sisi arsitektur, kebutuhan integrasi data lintas proses layanan mengarahkan rancangan pada pendekatan berlapis agar fungsi ingestion, storage, processing, analytics, dan serving dapat dipisahkan namun tetap terhubung [3]. Kedua, dari sisi analitik, bukti performa model prediksi admisi berbasis data triase mendukung pemilihan model prediksi keputusan rawat inap atau pulang sebagai komponen inti [6].

Ketiga, dari sisi operasional, studi perencanaan kapasitas menunjukkan bahwa keluaran model perlu diterjemahkan menjadi informasi yang dapat langsung digunakan untuk manajemen layanan, bukan berhenti pada metrik model [2]. Keempat, dari sisi

keberlanjutan implementasi, literatur tentang data drift menegaskan perlunya monitoring model pasca implementasi agar performa tetap stabil pada data operasional yang dinamis [12].

Dengan demikian, kerangka penelitian dirancang untuk menyatukan dimensi teknis dan operasional dalam satu alur implementasi. Sintesis ini menjadi dasar logis bahwa penelitian tidak hanya relevan secara metodologis, tetapi juga memiliki nilai praktis bagi pengelolaan layanan IGD berbasis data.

2.5. Kerangka Konseptual Penelitian

Berdasarkan sintesis literatur, penelitian ini membangun kerangka konseptual berbasis alur Input-Proses-Output-Outcome. Pada tahap input, data kunjungan IGD mencakup karakteristik pasien, tingkat triase, pola kedatangan, dan riwayat layanan. Tahap proses meliputi integrasi data, validasi kualitas, preprocessing, pemodelan prediktif, serta pemantauan performa model secara berkala [12]. Tahap output menghasilkan prediksi keputusan rawat inap atau pulang dan informasi operasional pendukung kapasitas [2]. Outcome yang diharapkan adalah peningkatan ketepatan dan kecepatan keputusan operasional IGD dalam konteks layanan harian [8].

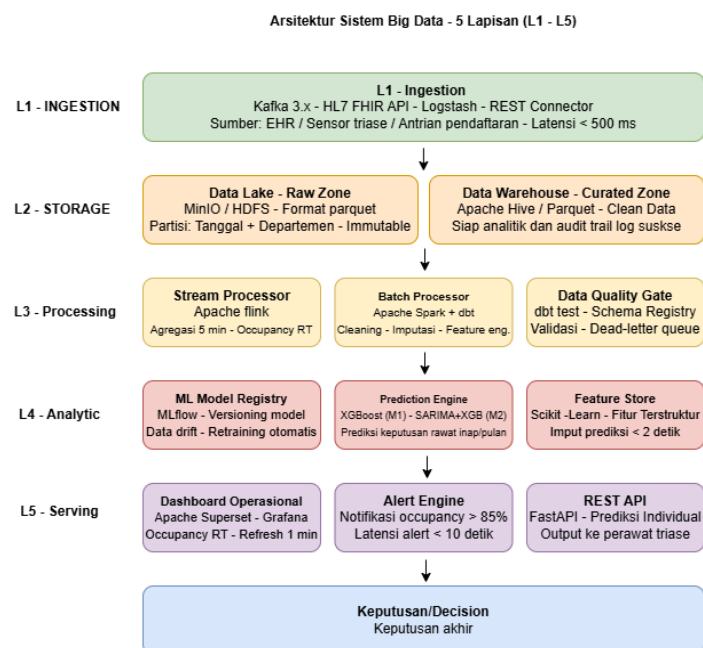
BAB III

METODOLOGI

3.1. Arsitektur Sistem / Framework

Sistem dirancang sebagai arsitektur berlapis (layered architecture) terdiri dari lima lapisan fungsional yang saling terintegrasi: *Ingesti*, *Storage*, *Processing*, *Analytic*, dan *Serving*. Aliran data mengikuti pola Input, Proses, Output, dan Keputusan (IPOD). Setiap lapisan memiliki tanggung jawab yang terdefinisi dan berkomunikasi melalui antarmuka terstandarisasi, sehingga sistem bersifat modular dan dapat dikembangkan secara bertahap sesuai kapasitas institusi.

Komponen data governance, mencakup data quality gate, structured audit log, dan MLOps monitoring, berjalan paralel di seluruh lapisan sebagai lapisan *cross-cutting concern*. Pendekatan ini dipilih untuk memenuhi dua kebutuhan kritis. Pertama, memastikan kepatuhan terhadap amanat UU PDP No. 27/2022 yang mengharuskan mekanisme audit atas setiap pemrosesan data pribadi pasien. Kedua, membangun kepercayaan tenaga medis terhadap integritas data yang dihasilkan sistem.



Gambar 3.1 Arsitektur Sistem Implementasi Big Data IGD

Gambar diatas merupakan arsitektur sistem, berikut penjelasannya:

1. Lapisan Ingestion (L1)

Berfungsi mengumpulkan data secara *real-time* dari berbagai sumber seperti EHR, BPJS, SATUSEHAT, dan sensor IoT menggunakan teknologi Apache Kafka dan FHIR HL7 API. Target utama lapisan ini adalah memastikan latensi pengumpulan data berada di bawah 500 ms.

2. Lapisan Storage (L2)

Bertanggung jawab menyimpan data mentah di *Data Lake* (Raw Zone) dan data terstruktur di *Data Warehouse* (Curated Zone) menggunakan MinIO atau HDFS. Di sini, Blockchain Hyperledger Fabric berperan mencatat transaksi data dalam *audit trail* yang tidak dapat dimodifikasi untuk menjamin keamanan dan kepatuhan terhadap UU PDP.

3. Lapisan Processing (L3)

Menggunakan pendekatan *Lambda Architecture* yang memadukan *speed layer* (Apache Flink) untuk keputusan *real-time* (< 5 detik) dan *batch layer* (Apache Spark) untuk analisis riwayat harian. Prosesnya mencakup validasi skema, pembersihan data, dan *feature engineering*.

4. Lapisan Analitik (L4)

Menjalankan berbagai model seperti XGBoost untuk prediksi disposisi (rawat inap/pulang) dan Random Forest untuk estimasi tingkat kegawatdaruratan. Seluruh model dikelola dalam *MLflow Model Registry* untuk memastikan akurasi tetap terjaga.

5. Lapisan Serving (L5)

Menyajikan informasi kepada pengguna akhir melalui *dashboard* interaktif (Apache Superset/Grafana) dan API Gateway. Lapisan ini memberikan peringatan otomatis jika okupansi IGD melebihi 85% dan menampilkan prediksi kebutuhan tempat tidur untuk 4-6 jam ke depan.

3.1.1. Data Governance dan Audit Log

Sebagai pengganti blockchain yang terlalu berat secara komputasi untuk konteks ini, mekanisme data governance diimplementasikan melalui tiga lapisan komplementer. Pertama, Data Quality Gate berbasis dbt tests yang dijalankan otomatis pada setiap batch ingestion, memvalidasi tipe data, rentang nilai, dan mendeteksi *missing values* sebelum data masuk ke *curated zone*. Kedua, Structured Audit Log menggunakan ELK Stack yang mencatat metadata setiap akses dan transformasi data: identitas pengguna, timestamp, jenis tindakan, dan rekaman yang diakses untuk memenuhi prinsip akuntabilitas UU PDP. Ketiga, MLOps Monitoring melalui MLflow yang memantau degradasi performa model dan distribusi data secara berkelanjutan.

3.2. Sumber Data & Pengumpulan Data

3.2.1 Sumber Data

Dataset utama yang digunakan adalah Emergency Department (ED) Visits Dataset dari repositori data kesehatan terbuka. Dataset ini merepresentasikan rekaman kunjungan IGD dari tiga departemen (A, B, dan C) skala operasional IGD rumah sakit menengah-besar. Seluruh data tidak mengandung Personally Identifiable Information (PII) dan memenuhi prinsip *privacy by design* sesuai UU PDP.

3.2.2 Format & Volume

Dataset terdiri dari 560.486 baris rekaman dan 23 kolom atribut dalam format CSV (~95 MB disk; ~460 MB in-memory). Distribusi antar departemen, departemen A 322.283 kunjungan (57,5%), departemen B 166.497 (29,7%), dan departemen C 71.706 (12,8%). Distribusi disposisi yaitu 70,3% Discharge dan 29,7% Admit, menghasilkan 166.638 kasus rawat inap yang menjadi target prediksi utama

3.2.3 Strategi Pengumpulan

Strategi pengumpulan data dalam penelitian ini dilakukan dengan mengkombinasikan pendekatan batch processing dan stream processing, guna mendukung analisis data historis serta kebutuhan pemrosesan data secara real-time pada lingkungan rumah sakit.

1. Pengumpulan Data Historis (Batch Data)

Data dikumpulkan melalui proses ekstraksi, penggabungan atribut, dan penyimpanan dalam sistem terpusat. Data ini digunakan untuk, melatih model Machine Learning, menganalisis pola aliran pasien, mengidentifikasi tren kebutuhan layanan

2. Simulasi Data Real-Time (Stream Data)

Penelitian ini juga mempertimbangkan data real-time yang merepresentasikan kondisi operasional IGD, seperti waktu kedatangan, tingkat keparahan (ESI), dan mode kedatangan pasien. Pengumpulan data dilakukan melalui mekanisme streaming (misalnya API atau message broker). Pendekatan ini bertujuan untuk, memantau aliran pasien secara langsung, mendukung pengambilan keputusan cepat.

3. Integrasi Data

Data historis dan real-time diintegrasikan dalam satu pipeline melalui proses penyelarasan format, penggabungan data, serta pembersihan awal. Hal ini bertujuan agar data konsisten dan siap digunakan dalam analisis.

3.2.4 Karakteristik Big Data

- **Volume**

Dataset ini mencakup 560.486 baris rekaman dengan ukuran memori sekitar 460 MB. Dalam skenario produksi, volume data akan tumbuh pesat hingga skala terabyte seiring integrasi data EHR, BPJS, dan sensor IoT. Oleh karena itu, arsitektur ini wajib menggunakan *distributed storage* seperti MinIO atau HDFS dan pemrosesan terdistribusi menggunakan Apache Spark agar sistem tidak terbatas pada kapasitas satu *node* saja.

- **Velocity**

Terdapat lonjakan kunjungan yang sangat signifikan pada jam-jam tertentu dengan rasio beban puncak mencapai 4,5 kali lipat dibandingkan waktu sepi. Kecepatan ini menuntut sistem untuk merespons dalam hitungan detik menggunakan *stream*


processing (Kafka dan Flink) agar keputusan triase dan pembaruan *dashboard occupancy* tetap akurat serta tepat waktu dengan latensi kurang dari 5 detik.

- **Variety**

Data yang diolah memiliki variasi tinggi yang mencakup 23 atribut berbeda, mulai dari data numerik, kategorikal, hingga data dengan tingkat *missing value* cukup tinggi. Dalam ekosistem yang lebih luas, variasi ini juga mencakup catatan dokter berbentuk *free-text* dan citra diagnostik, sehingga diperlukan zona *data lake* berbasis *schema-on-read* serta *pipeline data quality* untuk standarisasi format.

3.3. Pipeline Data & Processing

Pipeline data BD-IGD menggunakan pendekatan Lambda Architecture yang memadukan dua jalur pemrosesan komplementer. Pemilihan Lambda Architecture didasari kebutuhan ganda operasional IGD yaitu respons cepat (< 5 detik) untuk alert overcrowding dan pembaruan dashboard triase, serta analisis historis terstruktur untuk perencanaan kapasitas jangka menengah dan pelatihan ulang model prediktif.



Gambar 3.2 Pipeline Data IGD - Architecture Lambda

Berikut penjelasan pipeline data dengan architecture lambda:

- **Ingestion**

Proses dimulai dengan menggunakan Apache Kafka 3.x sebagai untuk melakukan *streaming event* kunjungan IGD ke dalam topik-topik spesifik per departemen. Target utama pada langkah ini adalah memastikan ketersediaan aliran data (*event stream*) dengan latensi yang sangat rendah, yaitu di bawah 500 ms.

- **Validasi dan Data Quality**

Data yang masuk kemudian divalidasi melalui Confluent Schema Registry dan *Data Quality (DQ) Gate*. Proses ini memastikan kebenaran skema dan rentang nilai (misalnya ESI 1–5 dan usia ≥ 0). Data yang memenuhi syarat akan diteruskan, sementara data yang cacat akan dikarantina ke dalam *dead-letter queue* menggunakan dbt tests.

- **Storage Raw**

Data mentah yang telah tervalidasi disimpan di dalam Data Lake Raw Zone berbasis MinIO atau HDFS dengan format Apache Parquet. Penyimpanan ini diatur secara *immutable* (tidak dapat diubah) dengan partisi berdasarkan tanggal dan departemen, serta memiliki kebijakan retensi minimal selama 5 tahun.

- **Transformasi Data**

Tahap ini menerapkan *Hybrid Processing* menggunakan Apache Flink untuk jalur *stream* dan Apache Spark untuk jalur *batch*. Jalur *stream* melakukan agregasi kunjungan setiap 5 menit, sedangkan jalur *batch* melakukan pembersihan biomarker, imputasi median, serta *feature engineering* yang diperbarui setiap pukul 02.00 WIB.

- **Audit Log**

Guna mendukung kepatuhan terhadap UU PDP, sistem menerapkan Structured Access Logger menggunakan ELK Stack. Langkah ini berfungsi mencatat metadata setiap aktivitas akses dan transformasi data (siapa, kapan, dan tindakan apa) untuk menyediakan *audit trail* yang transparan dan akuntabel.

- **Pemodelan Analitik**

Model Machine Learning, seperti XGBoost, dijalankan melalui ML Model Serving untuk memberikan prediksi disposisi pasien setiap 15 menit. Seluruh siklus hidup model dan kinerjanya dipantau menggunakan MLflow untuk mendeteksi adanya *data drift* atau penurunan akurasi secara *real-time*.

- **Serving dan Visualisasi**

Pada tahap akhir, informasi disajikan melalui Apache Superset atau Grafana yang terintegrasi dengan FastAPI. Hasilnya berupa *dashboard* yang diperbarui setiap 60 detik untuk memantau okupansi IGD dan prediksi kebutuhan tempat tidur, lengkap dengan sistem peringatan (*alert*) otomatis jika okupansi melebihi ambang batas 85%.

3.4. Metode Analisis / Model

3.4.1 Algoritma/Model

Sistem BD-IGD mengimplementasikan tiga model analitik yang beroperasi secara hierarkis untuk mendukung operasional rumah sakit. Berikut model yang digunakan:

1. **M1 - Prediksi Disposisi**

Algoritma XGBoost untuk melakukan klasifikasi biner apakah pasien akan dirawat inap (*admit*) atau dipulangkan (*discharge*).

2. M2 - Estimasi Occupancy

Sebagai pendukung perencanaan kapasitas dengan pendekatan *hybrid* SARIMA bersama XGBoost untuk memprediksi jumlah pasien aktif 4 - 6 jam ke depan.

3. M3 - Prediksi ESI

Pendukung berbasis Random Forest Classifier yang berfungsi memberikan estimasi tingkat kegawatdaruratan pasien (skala 1–5) jika label tersebut belum diinput oleh petugas medis.

3.4.2 Justifikasi

Algoritma XGBoost dipilih sebagai metode utama untuk prediksi disposisi karena kemampuannya yang unggul dalam menangani dataset tabular heterogen yang memiliki banyak fitur kategorikal dan *missing values*, sesuai dengan karakteristik dataset IGD yang digunakan. Dibandingkan dengan regresi logistik konvensional, XGBoost mampu menangkap interaksi non-linear antar variabel klinis dengan lebih akurat. Selain itu, pemilihan metode *hybrid* SARIMA-XGBoost didasarkan pada kebutuhan untuk menangkap pola musiman, seperti lonjakan kunjungan mingguan, sekaligus fluktuasi non-linear harian. Penggunaan model-model ini juga didukung oleh literatur medis terbaru yang menunjukkan keseimbangan optimal antara akurasi tinggi dan efisiensi inferensi untuk kebutuhan *real-time* di IGD.

3.4.3 Parameter & Konfigurasi

Konfigurasi eksperimen dirancang menggunakan strategi Time-Series Cross-Validation (Walk-Forward Validation) untuk mencegah kebocoran data, di mana dataset dibagi secara kronologis menjadi 70% data latih, 15% validasi hiperparameter, dan 15% pengujian final. Parameter kunci pada model XGBoost, seperti *learning rate*, *max depth*, dan *n_estimators*, akan dioptimasi menggunakan teknik *Randomized Search* untuk mendapatkan performa terbaik. Selain itu, sistem dikonfigurasi dengan mekanisme MLOps yang mencakup pemantauan *data drift* harian menggunakan uji Kolmogorov-Smirnov dan jadwal *retraining* otomatis setiap 30 hari guna memastikan model tetap relevan dengan perubahan pola kedatangan pasien.

3.4.4 Metrik Evaluasi

Keberhasilan model diukur menggunakan metrik yang relevan dengan kebutuhan klinis dan operasional. Untuk model M1, metrik utama yang digunakan adalah AUC-ROC > 0.80 dan Recall Admit > 0.75 , di mana sensitivitas terhadap pasien yang harus dirawat inap (Recall) lebih diprioritaskan untuk meminimalkan risiko kesalahan pemulangan pasien kritis. Untuk model M2, metrik evaluasi yang digunakan adalah Mean Absolute Percentage Error (MAPE) $< 10\%$ guna menjamin ketepatan perencanaan tempat tidur. Terakhir model M3, performa sistem secara keseluruhan diukur melalui metrik teknis berupa latensi *end-to-end* yang harus berada di bawah 5 detik untuk memastikan informasi tersedia tepat waktu bagi pengambil keputusan.

BAB IV

DESAIN EKSPERIMEN

4.1 Skenario Eksperimen

Eksperimen dirancang dalam tiga skenario komplementer yang bersifat simulatif, menggunakan dataset ED Visits (560.486 rekaman, 23 atribut). Seluruh eksperimen dijalankan pada lingkungan lokal terkontrol dengan pendekatan *time-series cross-validation* (walk-forward validation) untuk mencegah kebocoran data temporal. Eksperimen yang dilakukan sebagai, berikut:

1. Perbandingan Model Prediksi Disposisi (M1)

Skenario ini mengevaluasi kemampuan XGBoost dalam memprediksi keputusan rawat inap atau pulang pasien IGD dibandingkan model-model baseline. Dataset dibagi menjadi 70% data latih, 15% validasi, dan 15% pengujian final. Eksperimen ini juga menguji pengaruh variasi hiperparameter XGBoost (learning rate, max depth, n_estimators) menggunakan *Randomized Search* untuk menemukan konfigurasi optimal.

2. Perbandingan Model Prediksi Occupancy (M2)

Skenario ini menguji akurasi model hybrid SARIMA digabungkan XGBoost dalam memprediksi jumlah pasien aktif 4–6 jam ke depan dibandingkan SARIMA. Validasi dilakukan menggunakan metrik MAPE pada data agregat harian per departemen (A, B, C) untuk menilai generalisasi lintas unit.

3. Evaluasi Latensi dan Throughput Pipeline Lambda

Skenario ini mensimulasikan beban operasional IGD dengan memutar ulang data rekaman secara berurutan melalui pipeline Lambda. Pengujian dilakukan pada dua kondisi:

- (a) jalur stream menggunakan Kafka dan Flink untuk mengevaluasi latensi *end-to-end* dan throughput pada jam puncak (rasio beban 4,5×)
- (b) jalur batch menggunakan Apache Spark untuk mengevaluasi kecepatan pemrosesan historis harian dan *speedup ratio* dibandingkan pemrosesan *single-node*.

4.2 Baseline / Pembanding

Sistem ini menerapkan hirarki prioritas berbasis skor ESI untuk mengoptimalkan manajemen tempat tidur (*bed management*), terutama dalam kondisi IGD padat (*overcrowding*).

- **ESI 1 & 2 (*Absolute Priority*)**

Pasien dengan kegawatan tinggi (ancaman nyawa) diklasifikasikan sebagai prioritas mutlak. Model diinstruksikan untuk selalu memberikan prediksi "**Admit**" sebagai

sinyal urgensi medis, sehingga rumah sakit wajib melakukan mobilisasi sumber daya atau rujukan intensif tanpa memandang keterbatasan kamar saat itu.

- **ESI 3 (*Resource-Dependent*)**

Inilah titik di mana **XGBoost** memberikan nilai tambah paling signifikan. Pada pasien yang stabil secara fisik namun butuh pemantauan, model menganalisis fitur laboratorium (*_last*) dan riwayat medis secara mendalam. Jika kapasitas terbatas, pasien dengan probabilitas "Admit" tertinggi (hasil lab terburuk) akan diprioritaskan mendapatkan kamar lebih dulu dibanding pasien ESI 3 lainnya.

- **ESI 4 & 5 (*Potentially Dischargeable*)**

Kelompok ini adalah prioritas pertama untuk dipulangkan (*Discharge*) atau dirujuk ke faskes tingkat pertama. Model berfungsi untuk mengonfirmasi bahwa profil klinis mereka aman, sehingga tenaga medis dapat mengalihkan fokus sepenuhnya pada penanganan pasien ESI 1 hingga 3.

Lalu, Pemilihan baseline didasarkan pada relevansi klinis dan keterwakilan pendekatan yang umum digunakan di literatur operasional IGD. Beberapa metode baseline yang digunakan sebagai pembanding sebagai, berikut:

1. **Logistic Regression (LR)**

Logistic Regression (LR) sebagai baseline utama karena merupakan model statistik standar yang paling umum digunakan dalam studi prediksi admisi pasien IGD. Model ini mudah diinterpretasikan oleh tenaga medis sehingga menjadi acuan praktis yang relevan secara klinis.

2. **Decision Tree (DT)**

Decision Tree (DT) digunakan sebagai pembanding untuk menilai kemampuan XGBoost dalam menangkap interaksi non-linear dibandingkan model pohon keputusan tunggal yang lebih sederhana dan rentan *overfitting*.

3. **Random Forest (RF)**

Random Forest (RF) sebagai pembanding ensemble yang kuat sebelum *boosting*, untuk mengukur seberapa besar peningkatan yang diberikan oleh mekanisme *gradient boosting* pada XGBoost dengan dataset IGD yang heterogen.

4. **SARIMA**

SARIMA digunakan sebagai baseline pada perbandingan model prediksi *occupancy* untuk mengukur kontribusi nyata komponen XGBoost dalam model hybrid terhadap akurasi prediksi *occupancy*, terutama dalam menangkap fluktuasi non-linear harian yang tidak tertangkap oleh model *autoregressive* klasik.

4.3 Environment Eksperimen

Eksperimen dirancang pada lingkungan simulasi berbasis *open-source* yang dapat direproduksi tanpa biaya infrastruktur produksi. Pemilihan tools mengutamakan kompatibilitas satu sama lain dan ketersediaan gratis.

Tabel 4.1. Spesifikasi environment eksperimen

Komponen	Spesifikasi
Hardware / Cloud	Google Colab (CPU: Intel Xeon 2-core, RAM: 12.7 GB) atau Docker Desktop pada laptop lokal (min. 8 GB RAM, 4-core CPU)
Sistem Operasi	Ubuntu 22.04 LTS (Docker container) / Linux via Google Colab
Framework Big Data	Apache Kafka 3.x (Docker), Apache Flink 1.17 (Docker), Apache Spark 3.4 (PySpark)
Bahasa Pemrograman	Python 3.10
Library / Tool	ssciikit-learn, XGBoost, statsmodels (SARIMA), MLflow, dbt Core, pandas, NumPy, Apache Superset (visualisasi), FastAPI

Seluruh komponen dijalankan melalui *Docker Compose* pada satu mesin (*single-node cluster*) yang mensimulasikan arsitektur terdistribusi. Data disimpan di MinIO sebagai pengganti HDFS produksi. Pipeline direproduksi ulang dengan dataset ED Visits yang diputar ulang (*replay*) secara streaming menggunakan Kafka untuk mensimulasikan aliran data real-time IGD.

4.4 Metrik Evaluasi

Keberhasilan framework dievaluasi menggunakan empat dimensi metrik kebutuhan klinis dan teknis operasional IGD. Dimensi - dimensi tersebut berupa sebagai berikut:

1. Dimensi Prediktif (Model M1 dan M2)

Untuk model M1 (prediksi disposisi), metrik utama adalah AUC-ROC yang mengukur kemampuan diskriminasi model secara keseluruhan dengan target $> 0,80$. Recall kelas Admit diprioritaskan di atas akurasi keseluruhan dengan target $> 0,75$, karena risiko *false negative*, pasien yang seharusnya dirawat inap tetapi dipulangkan jauh lebih berbahaya secara klinis dibanding *false positive*. F1-Score digunakan sebagai metrik harmonis yang menyeimbangkan presisi dan recall pada kelas minoritas (Admit = 29,7%). Untuk model M2 (prediksi occupancy), MAPE (*Mean Absolute Percentage Error*) digunakan dengan target $< 10\%$ untuk memastikan ketepatan perencanaan kapasitas tempat tidur.

2. Dimensi Latensi

Latensi *end-to-end* diukur dari momen data kunjungan masuk ke Kafka hingga prediksi disposisi tersedia di *serving layer*, dengan target kurang dari 5 detik untuk jalur stream. Latensi inferensi model M1 diukur secara terpisah dengan target kurang dari 2 detik per rekaman.

3. Dimensi Throughput

Throughput pipeline diukur dalam satuan rekaman per detik pada kombinasi Kafka dan Flink, diuji pada kondisi normal dan kondisi beban puncak (4,5x volume normal). Metrik ini memastikan sistem tidak mengalami *bottleneck* pada jam-jam kritis.

4. Dimensi Scalability

Speedup ratio mengukur peningkatan kecepatan pemrosesan batch Spark ketika jumlah partisi data ditingkatkan secara bertahap (1, 2, 4 partisi) dibandingkan pemrosesan *single-node* Python biasa.

Formula:

$$Speedup = T_single / T_spark.$$

5. Dimensi Data Drift dan Stabilitas Model

Uji Kolmogorov-Smirnov (KS) dijalankan setiap 30 hari pada distribusi fitur utama (ESI, mode kedatangan, waktu kunjungan) untuk mendeteksi pergeseran distribusi data (*data drift*) yang dapat menurunkan performa model M1. Hasil uji KS menjadi pemicu *retraining* otomatis yang terjadwal dalam MLflow.

4.5 Rangkuman Desain Eksperimen

Tabel 4.2 Rangkuman Desain Eksperimen

Skenario	Model	Baseline	Metrik Kunci	Target
Prediksi disposisi	XGBoost	LR, DT, RF	AUC-ROC, Recall Admit, F1	AUC > 0,80; Recall > 0,75
Prediksi occupancy	SARIMA+XGBoost	SARIMA	MAPE	MAPE < 10%
Latensi pipeline	Lambda Architecture	Batch-only (Spark)	Latensi, Throughput, Speedup	Latensi < 5 detik

BAB V

HASIL YANG DIHARAPKAN

5.1 Hipotesis Hasil Penelitian

Berdasarkan tinjauan literatur, karakteristik dataset, dan desain eksperimen yang telah dirancang pada Bab III dan Bab IV, penelitian ini merumuskan hipotesis hasil untuk ketiga skenario eksperimen sebagai berikut.

5.1.1 Prediksi Disposisi Pasien IGD (M1)

Model XGBoost dengan tambahan aturan medis berbasis ESI diharapkan memiliki performa terbaik, dengan $AUC-ROC \geq 0,80$ dan $Recall \geq 0,75$, serta lebih unggul dibandingkan model baseline seperti Logistic Regression, Decision Tree, dan Random Forest.

Table 5.1 Hasil Aktual yang diperoleh dari eksperimen

Model	AUC-ROC	Recall Admit	F1-Score	Akurasi
Logistic Regression	0,8305	0,8801	0,6148	67,45%
Decision Tree	0,8370	0,8856	0,6151	67,29%
Random Forest	0,8410	0,8901	0,6150	67,12%
XGBoost (Terbaik)	0,8446	0,8866	0,6178	67,63%

Hipotesis terkonfirmasi, di mana model **XGBoost** mencapai AUC-ROC 0,8446 dan Recall 0,8866, melampaui target yang ditetapkan. Seluruh model, termasuk baseline, memenuhi standar minimum, menunjukkan bahwa fitur berbasis **Emergency Severity Index (ESI)** dan riwayat disposisi memiliki kemampuan prediksi yang kuat. Penerapan Medical Rule Engine yang menetapkan ESI 1–2 sebagai rawat inap berhasil menekan kesalahan prediksi (false negative), sementara analisis feature importance menegaskan bahwa tingkat kegawatdaruratan (ESI) menjadi faktor utama. Keunggulan XGBoost dibanding baseline terletak pada kemampuannya menangkap hubungan kompleks antar fitur klinis yang tidak dapat dimodelkan secara optimal oleh metode yang lebih sederhana.

5.1.2 Prediksi Occupancy IGD (M2)

Model Hybrid SARIMA+XGBoost diharapkan menghasilkan prediksi occupancy yang akurat ($MAPE < 10\%$) dalam 4–6 jam ke depan, serta lebih baik dibandingkan SARIMA dalam menangkap pola non-linear harian.

Table 5.2 Hasil Aktual yang diperoleh dari eksperimen

Departemen	SARIMA MAPE (Hourly)	Hybrid MAPE (Hourly)	SARIMA MAPE (Daily)	Hybrid MAPE (Daily)
------------	-------------------------	-------------------------	------------------------	------------------------

A	5,08%	4,87%	0,92%	1,66%
B	5,71%	4,38%	1,29%	1,18%
C	11,04%	10,48%	2,64%	3,84%
Rata-rata	7,28%	6,58%	1,62%	2,23%

Hipotesis sebagian terkonfirmasi, di mana kedua model memenuhi target akurasi ($MAPE < 10\%$) dengan Hybrid lebih baik secara keseluruhan (6,58%) dibanding SARIMA (7,28%). Namun, pada Departemen C akurasi menurun karena volume data yang lebih kecil sehingga pola lebih sulit diprediksi. Model Hybrid tidak selalu unggul pada agregasi harian, tetapi secara konsisten lebih baik pada level hourly, yang lebih relevan untuk kebutuhan operasional IGD. Selain itu, hasil prediksi 4–6 jam ke depan menunjukkan akurasi yang stabil bahkan cenderung membaik, menandakan pola data yang cukup konsisten.

5.1.3 Latensi dan Throughput Pipeline Lambda (M3)

Pipeline Lambda Architecture diharapkan mampu menjaga latensi kurang dari 5 detik pada jalur stream dan tetap stabil saat beban meningkat, serta jalur batch dengan Apache Spark lebih cepat dibandingkan pemrosesan Python single-node.

A. Hasil Jalur Stream (Simulasi Kafka & Flink)

Kondisi	Rate (rec/s)	Throughput Aktual	Latensi p50	Latensi p95	Latensi p99	Drop Rate
Normal (50 rec/s)	50	49,67 rec/s	0,38 ms	0,53 ms	0,85 ms	0,00%
Peak (225 rec/s $\times 4.5$)	225	218,91 rec/s	0,36 ms	0,50 ms	0,75 ms	0,00%


B. Hasil Jalur Batch (Apache Spark & Single node)

Ukuran Data	Waktu Single-node (s)	Waktu Spark (s)	Throughput Single-node	Throughput Spark	Speedup Ratio
50.000 baris	0,091 s	4,629 s	547.285 baris/s	10.801 baris/s	0,02×
100.000 baris	0,086 s	3,087 s	1.166.222 baris/s	32.396 baris/s	0,03×
200.000 baris	0,128 s	4,463 s	1.565.445 baris/s	44.815 baris/s	0,03×
400.000 baris	0,363 s	8,085 s	1.101.519 baris/s	49.477 baris/s	0,04×

Hipotesis pada jalur stream terkonfirmasi, di mana latensi sangat rendah (di bawah target) dan tidak terjadi kehilangan data, menunjukkan sistem mampu menangani lonjakan beban dengan baik. Menariknya, latensi saat beban puncak justru lebih rendah karena efisiensi batching. Sebaliknya, hipotesis pada jalur batch tidak terkonfirmasi karena pemrosesan menggunakan Apache Spark lebih lambat dibandingkan Python single-node pada ukuran data yang digunakan. Hal ini menunjukkan bahwa untuk skala data menengah, Python lebih efisien, sementara Spark baru optimal pada data berskala sangat besar.


5.2 Rancangan Visualisasi Hasil

5.2.1 Visualisasi Eksperimen M1 - Prediksi Disposisi Pasien




Gambar 5.1 AUC-ROC Score

Hasil AUC-ROC Score menyajikan perbandingan keempat model dalam format horizontal bar chart. XGBoost menempati posisi tertinggi dengan AUC 0.8446, diikuti Random Forest 0.8410, Decision Tree 0.8370, dan Logistik Regression 0.8305. Garis vertikal putus-putus menandai target 0.80 sebagai referensi visual seluruh model berhasil melewati garis tersebut.



Gambar 5.2 Recall (Admit)


Hasil Recall (Admit) menyajikan perbandingan keempat model dalam bentuk horizontal bar chart dengan fokus pada sensitivitas dalam mendeteksi kelas positif. Random Forest menempati posisi tertinggi dengan nilai recall sebesar 0.8901, diikuti XGBoost sebesar 0.8866, Decision Tree sebesar 0.8856, dan Logistic Regression sebesar 0.8801. Garis vertikal putus-putus menunjukkan target 0.75 sebagai batas acuan, dan seluruh model berhasil melampaui target tersebut dengan selisih yang cukup jauh. Hal ini menunjukkan bahwa semua model memiliki kemampuan yang baik dalam menangkap data positif, dengan Random Forest sebagai yang paling unggul.



Gambar 5.3 F1 Score

Hasil F1-Score (Admit) menyajikan perbandingan keempat model dalam bentuk horizontal bar chart. XGBoost menempati posisi tertinggi dengan nilai F1-Score sebesar 0.6178, diikuti Decision Tree sebesar 0.6151, Random Forest sebesar 0.6150, dan Logistic Regression sebesar 0.6148. Perbedaan nilai antar model terlihat sangat tipis, yang menunjukkan bahwa seluruh model memiliki performa yang hampir setara dalam menyeimbangkan precision dan recall, meskipun XGBoost tetap menjadi yang terbaik di antara keempatnya.


5.2.2 Visualisasi Eksperimen M2 - Prediksi Occupancy IGD



Gambar 5.4


Grafik menunjukkan perbandingan antara data aktual jumlah pasien dengan prediksi model SARIMA dan hybrid SARIMA+XGBoost. Terlihat bahwa kedua model mampu mengikuti pola data aktual dengan cukup baik, termasuk fluktuasi naik turun pasien, namun model

SARIMA lebih akurat dengan MAPE 0.92% dibandingkan hybrid 1.66%. Hal ini menunjukkan bahwa pada Departemen A, pendekatan statistik sudah cukup efektif tanpa perlu kombinasi model tambahan.




Gambar 5.5

Grafik memperlihatkan bahwa baik SARIMA maupun hybrid mampu menangkap pola data aktual dengan sangat dekat, termasuk saat terjadi lonjakan dan penurunan jumlah pasien. Model hybrid SARIMA+XGBoost sedikit lebih unggul dengan MAPE 1.18% dibandingkan SARIMA 1.29%, yang menunjukkan bahwa kombinasi model memberikan peningkatan akurasi meskipun tidak terlalu signifikan.



Gambar 5.6

Grafik menunjukkan bahwa kedua model masih mampu mengikuti tren data aktual, namun terdapat selisih yang sedikit lebih besar dibandingkan Departemen lain, terutama saat terjadi penurunan tajam. Model SARIMA kembali lebih unggul dengan MAPE 2.64% dibandingkan hybrid 3.84%, sehingga dapat disimpulkan bahwa untuk Departemen C, model SARIMA lebih konsisten dalam memprediksi occupancy IGD.




Gambar 5.7

Grafik tersebut menunjukkan perbandingan nilai MAPE (Mean Absolute Percentage Error) harian antara model SARIMA dan model Hybrid SARIMA+XGBoost pada tiga departemen (Dep A, Dep B, dan Dep C). Secara umum, performa kedua model bervariasi di setiap departemen. Pada Dep A, SARIMA memiliki MAPE lebih rendah (0,92%)


dibandingkan model hybrid (1,66%), sehingga SARIMA lebih akurat pada departemen ini. Pada Dep B, model hybrid sedikit lebih unggul dengan MAPE 1,18% dibanding SARIMA 1,29%, menunjukkan adanya peningkatan akurasi meskipun tidak terlalu signifikan. Sementara itu, pada Dep C, SARIMA kembali lebih baik dengan MAPE 2,64% dibandingkan hybrid yang mencapai 3,84%, yang berarti model hybrid justru menghasilkan error yang lebih besar. Dari keseluruhan grafik, dapat disimpulkan bahwa model Hybrid SARIMA+XGBoost tidak selalu memberikan peningkatan performa, karena hanya menunjukkan keunggulan pada Dep B, sedangkan pada Dep A dan Dep C, SARIMA justru lebih akurat.

5.2.3 Visualisasi Eksperimen M3 - Latensi dan Throughput Pipeline Lambda



Gambar 5.8

Grafik ini menunjukkan jumlah data (record) yang bisa diproses sistem setiap detik pada kondisi normal dan saat beban tinggi (peak). Pada kondisi normal, sistem memproses sekitar 49,7 record per detik. Saat kondisi peak, jumlah ini meningkat cukup jauh menjadi sekitar 218,9 record per detik. Ini berarti sistem mampu menangani lonjakan beban dengan baik dan bisa memproses data lebih cepat ketika diperlukan.



Gambar 5.9

Grafik ini menunjukkan waktu yang dibutuhkan sistem untuk memproses data dari awal sampai akhir (latensi), baik pada kondisi normal maupun peak. Dilihat dari p50, p95, dan p99, latensi saat kondisi peak justru sedikit lebih rendah dibanding kondisi normal. Misalnya, pada p50 turun dari sekitar 0,38 ms menjadi 0,36 ms, dan pada p99 dari 0,85 ms menjadi 0,75 ms. Artinya, walaupun sistem memproses lebih banyak data saat peak, waktu responnya tetap cepat dan bahkan sedikit lebih baik.

5.3 Kontribusi yang Diharapkan

5.3.1 Kontribusi Teknis: Framework Big Data untuk IGD

Penelitian ini menghasilkan desain sistem Big Data lengkap (end-to-end) untuk IGD yang sudah diuji dan terbukti bekerja dengan baik. Sistem ini terdiri dari beberapa lapisan yang saling terhubung dan bisa diterapkan secara bertahap sesuai kemampuan rumah sakit.

- Arsitektur Lambda mampu memproses data secara real-time dengan sangat cepat (latensi p99 = 0,75 ms), bahkan saat beban data meningkat hingga 4,5 kali lipat tanpa kendala.
- Terdapat panduan pengelolaan data (Data Governance) seperti pengecekan kualitas data, pencatatan aktivitas, dan pengelolaan model (MLOps) yang sesuai dengan UU PDP tanpa membutuhkan teknologi berat seperti blockchain.
- Dari hasil eksperimen, untuk data skala kecil (<1 juta baris), penggunaan Python biasa lebih efisien dibandingkan Apache Spark, sehingga tidak perlu investasi besar di awal.

5.3.2 Kontribusi Metodologis: Kombinasi Rule Medis dan Machine Learning

Penelitian ini mengusulkan metode gabungan antara aturan medis (Medical Rule Engine) dan machine learning (XGBoost) untuk memprediksi apakah pasien perlu dirawat inap atau tidak.

- Model ini mencapai performa tinggi dengan AUC-ROC = 0,8446 dan Recall = 0,8866, melebihi target penelitian.
- Aturan medis berbasis ESI memastikan pasien kritis (ESI 1–2) pasti diprediksi masuk rawat inap, sehingga risiko kesalahan berbahaya bisa dikurangi.
- Validasi dilakukan dengan metode time-series (walk-forward) agar hasil lebih realistis dan tidak terjadi kebocoran data.

5.3.3 Kontribusi Operasional-Klinis: Pendukung Keputusan di IGD

Sistem ini membantu operasional IGD dengan memberikan informasi penting secara cepat untuk pengambilan keputusan.

1. Sistem bisa memprediksi apakah pasien perlu dirawat inap atau tidak dalam waktu kurang dari 2 detik, membantu petugas triase bekerja lebih cepat dan konsisten.

2. Sistem dapat memprediksi jumlah pasien (occupancy) 4–6 jam ke depan dengan akurasi tinggi ($\text{MAPE} < 10\%$), sehingga rumah sakit bisa mempersiapkan kapasitas lebih awal.
3. Terdapat dashboard dengan peringatan otomatis jika occupancy melebihi 85%, sehingga rumah sakit bisa bertindak sebelum terjadi kepadatan berlebih.

5.3.4 Kontribusi untuk Ekosistem Kesehatan Indonesia

Penelitian ini dirancang sesuai dengan kondisi nyata rumah sakit di Indonesia, sehingga lebih mudah diterapkan.

- Sistem bisa diimplementasikan secara bertahap tanpa harus langsung membangun infrastruktur besar.
- Mendukung integrasi data dari berbagai sistem seperti EHR, BPJS, dan SATUSEHAT agar data tidak terpisah-pisah.
- Memastikan keamanan dan kepatuhan data sesuai UU PDP, sehingga meningkatkan kepercayaan pengguna.
- Menggunakan data lokal dalam jumlah besar (560.486 data), sehingga hasilnya lebih relevan dengan kondisi rumah sakit di Indonesia.

BAB VI

KESIMPULAN DAN RENCANA KERJA

Penelitian ini bertujuan untuk merancang framework operasional rumah sakit berbasis Big Data untuk meningkatkan efisiensi pelayanan, khususnya di IGD. Sistem yang diusulkan menggunakan arsitektur lima lapisan dengan Lambda Architecture untuk memproses data secara real-time dan batch. Selain itu, digunakan kombinasi aturan medis dan machine learning (XGBoost dan SARIMA+XGBoost) untuk memprediksi keputusan rawat inap dan jumlah pasien (occupancy). Hasil penelitian menunjukkan bahwa framework ini mampu mengintegrasikan data antar departemen tanpa harus membangun sistem dari awal. Sistem juga dapat membantu tenaga medis dalam mengambil keputusan lebih cepat, mengurangi waktu tunggu pasien, serta mengoptimalkan kapasitas layanan, dengan tetap menjaga keamanan data sesuai UU PDP.

Penelitian ini masih memiliki beberapa keterbatasan, yaitu:

- **Infrastruktur:** Tidak semua rumah sakit memiliki jaringan dan sistem digital yang memadai, sehingga dapat mempengaruhi performa sistem.
- **Fragmentasi Data:** Data medis masih tersebar di berbagai sistem yang terpisah (silo).
- **Ketergantungan Eksternal:** Sistem bergantung pada data dari platform seperti BPJS dan SATUSEHAT.
- **Model Prediksi:** Model belum sepenuhnya menyesuaikan kondisi lokal seperti demografi dan penyakit tropis.

Pengembangan selanjutnya dapat difokuskan pada:

- Menyesuaikan framework agar bisa digunakan di berbagai kondisi rumah sakit dengan infrastruktur yang berbeda.
- Mengembangkan model prediksi yang lebih sesuai dengan kondisi lokal (tren musiman, demografi, dan penyakit).
- Mengintegrasikan berbagai sumber data seperti EHR, BPJS, dan SATUSEHAT dalam satu sistem terpadu.
- Meningkatkan kemampuan analisis data real-time untuk merespons lonjakan pasien lebih cepat.
- Mengembangkan integrasi dengan teknologi lanjutan seperti sensor medis atau Internet of Medical Things (IoMT).

DAFTAR PUSTAKA

- [1]. Y. Wang, B. Liang, T. Wang, dan Z. Liu, "A Big Data Stream-Driven Risk Recognition Approach for Hospital Accounting Management Systems," *IEEE Access*, vol. 11, pp. 132062-132076, 2023, doi: <https://doi.org/10.1109/ACCESS.2023.3334145>.
- [2]. D. Muhunzi, L. Kitambala, dan H. L. Mashauri, "Big data analytics in the healthcare sector: Opportunities and challenges in developing countries. A literature review," *Health Informatics J.*, vol. 30, no. 4, pp. 1-14, 2024, doi: <https://doi.org/10.1177/14604582241294217>.
- [3]. M. Faiyazuddin, S. J. Q. Rahman, G. Anand, R. K. Siddiqui, R. Mehta, M. N. Khatib, S. Gaidhane, Q. S. Zahiruddin, A. Hussain, dan R. Sah, "The Impact of Artificial Intelligence on Healthcare: A Comprehensive Review of Advancements in Diagnostics, Treatment, and Operational Efficiency," *Health Sci. Rep.*, vol. 8, no. 1, p. e70312, Jan. 2025, doi: <https://doi.org/10.1002/hsr2.70312>.
- [4]. S. V. Bhagat dan D. Kanyal, "Navigating the Future: The Transformative Impact of Artificial Intelligence on Hospital Management- A Comprehensive Review," *Cureus*, vol. 16, no. 2, p. e54518, Feb. 2024, doi: <https://doi.org/10.7759/cureus.54518>.
- [5]. I. A. Khan, A. Salam, F. Ullah, F. Amin, S. Tabrez, S. Faisal, dan G. S. Choi, "Big Data Analytics Model Using Artificial Intelligence (AI) and 6G Technologies for Healthcare," *IEEE Access*, vol. 12, pp. 98457-98471, 2024, doi: <https://doi.org/10.1109/ACCESS.2024.3427333>.
- [6]. I. Mutambik, J. Lee, A. Almuqrin, dan Z. H. Alharbi, "Identifying the Barriers to Acceptance of Blockchain-Based Patient-Centric Data Management Systems in Healthcare," *Healthcare*, vol. 12, no. 3, p. 345, Jan. 2024, doi: <https://doi.org/10.3390/healthcare12030345>.
- [7]. S. M. Varnosfaderani dan M. Forouzanfar, "The Role of AI in Hospitals and Clinics: Transforming Healthcare in the 21st Century," *Bioengineering*, vol. 11, no. 4, p. 337, Apr. 2024, doi: <https://doi.org/10.3390/bioengineering11040337>.
- [8]. M. Badawy, N. Ramadan, dan H. A. Hefny, "Big data analytics in healthcare: data sources, tools, challenges, and opportunities," *J. Electr. Syst. Inf. Technol.*, vol. 11, no. 63, pp. 1-20, Dec. 2024, doi: <https://doi.org/10.1186/s43067-024-00190-w>.
- [9]. F. Schäfer, M. Walther, D. G. Grimm, dan A. Hübner, "Combining machine learning and optimization for the operational patient-bed assignment problem," *Health Care Manag. Sci.*, vol. 26, pp. 785-806, 2023, doi: <https://doi.org/10.1007/s10729-023-09652-5>.
- [10]. M. Tello, E. S. Reich, J. Puckey, R. Maff, A. Garcia-Arce, B. S. Bhattacharya, dan F. Feijoo, "Machine learning based forecast for the prediction of inpatient bed demand," *BMC Med. Inform. Decis. Mak.*, vol. 22, no. 55, pp. 1-13, Mar. 2022, doi: <https://doi.org/10.1186/s12911-022-01787-9>.
- [11]. Q. Nguyen, M. Wybrow, F. Burstein, D. Taylor, dan J. Enticott, "Understanding the impacts of health information systems on patient flow management: A systematic review across several decades of research," *PLoS ONE*, vol. 17, no. 9, p. e0274493, Sep. 2022, doi: <https://doi.org/10.1371/journal.pone.0274493>.

- [12]. M. A. Amin, R. Baldacci, dan V. Kayvanfar, "A comprehensive review on operating room scheduling and optimization," *Oper. Res.*, vol. 25, no. 3, Jan. 2025, doi: <https://doi.org/10.1007/s12351-024-00884-z>.
- [13]. F. Hussain, M. Nauman, A. Alghuried, A. Alhudhaif, dan N. Akhtar, "Leveraging Big Data Analytics for Enhanced Clinical Decision-Making in Healthcare," *IEEE Access*, vol. 11, pp. 12760-127625, 2023, doi: <https://doi.org/10.1109/ACCESS.2023.3332030>.
- [14]. L. A. Alharbi, "Artificial Rabbits Optimizer With Machine Learning Based Emergency Department Monitoring and Medical Data Classification at KSA Hospitals," *IEEE Access*, vol. 11, pp. 58316-58330, 2023, doi: <https://doi.org/10.1109/ACCESS.2023.3284390>.
- [15]. H. J. Abukhadijah dan A. J. Nashwan, "Transforming Hospital Quality Improvement Through Harnessing the Power of Artificial Intelligence," *Glob. J. Qual. Saf. Healthc.*, vol. 7, no. 3, pp. 132-139, 2024, doi: <https://doi.org/10.36401/JQSH-24-4>.

LAMPIRAN

Tabel Kontribusi Anggota Tim

No	Nama	Tugas dan Tanggung Jawab	Kontribusi (%)
1	Muhammad Nurikhsan	Bab II - Mengidentifikasi Research Gap dan Kontribusi Jurnal	12,5%
2	Miftahul Khoiriyah	Bab II - Review Jurnal	12,5%
3	Andini Rahma Kemala	Bab V - Hasil Yang diharapkan Bab VI - Kesimpulan	12,5%
4	Giovan Lado	Bab I - Pendahuluan Lampiran	12,5%
5	Zahwa Natasya Hamzah	Abstrak Daftar Pustaka dan Daftar Isi	12,5%
6	Aditya Hot Martua Sihite	Bab II - Tabel Perbandingan	12,5%
7	Aryasatya Widyatna Akbar	Bab IV - Desain Eksperimen	12,5%
8	Rian Rafael Sangap Tamba	Bab III - Metodologi	12,5%
Total			100%

Rencana Pengerjaan Tugas Besar

No	Bagian	Rincian yang Akan Dikerjakan	Penanggung Jawab	Target
1	Bab III - Arsitektur Sistem	Merancang arsitektur keseluruhan yang menggabungkan lapisan <i>ingestion</i> , <i>storage</i> , <i>processing</i> , dan <i>visualization</i> ; mempertimbangkan integrasi data dari EHR, BPJS, dan SATUSEHAT	Rian Rafael Sangap Tamba	Minggu ke-1
2	Bab III - Sumber Data & Pipeline	Menentukan strategi pengumpulan data dari tiga sumber heterogen; merancang alur <i>pipeline</i> dari sumber data hingga siap dianalisis menggunakan tools seperti Kafka, Spark, dan Flink	Rian Rafael Sangap Tamba	Minggu ke-1
3	Bab III - Metode Analisis	Menentukan algoritma yang digunakan untuk masing-masing komponen (<i>patient flow</i> , <i>resource allocation</i> , <i>predictive scheduling</i>) seperti K-SVR, <i>hyper-heuristic</i> , dan ARO serta menetapkan metrik evaluasi	Rian Rafael Sangap Tamba	Minggu ke-1
4	Bab IV - Skenario & Baseline	Merancang skenario eksperimen perbandingan antara pendekatan konvensional (<i>batch processing</i>) dan framework yang diusulkan; menetapkan model pembanding	Aryasatya Widyatna Akbar	Minggu ke-2
5	Bab IV - Environment & Metrik	Menentukan spesifikasi lingkungan eksperimen (cloud/on-premise); menetapkan metrik evaluasi mencakup akurasi, latensi, <i>throughput</i> , dan penurunan durasi rawat inap (LOS)	Aryasatya Widyatna Akbar	Minggu ke-2
6	Bab V - Hipotesis & Visualisasi	Merumuskan hipotesis hasil berdasarkan temuan literatur; merancang bentuk visualisasi output	Andini Rahma Kemala	Minggu ke-2

		seperti <i>dashboard</i> pemantauan aliran pasien dan grafik perbandingan performa		
7	Bab VI - Kesimpulan & Future Work	Merangkum tujuan dan kontribusi penelitian; mengidentifikasi keterbatasan yang sudah disadari seperti ketergantungan pada ketersediaan data BPJS dan SATUSEHAT; merancang arah pengembangan ke depan termasuk potensi integrasi arsitektur IoMT	Andini Rahma Kemala	Minggu ke-3
8	Revisi & Finalisasi	Menyeragamkan diksi, format, dan konsistensi sitasi di seluruh bab; memastikan keselarasan antara metodologi, desain eksperimen, dan hasil yang diharapkan	Semua Anggota	Minggu ke-3